Universidade do Estado de Santa Catarina

Centro de Ciências Tecnológicas

Departamento de Ciência da Computação

Bacharelado em Ciência da Computação

Arthur Bertoli Silva e Mariana dos Santos

Detecção de Bordas com Operadores Gradientes (Sobel e Prewitt)

Processamento de Imagem

Prof. Gilmário B. Santos

Joinville

Novembro/2025

Sumário

1 Introdução ……..

2 Objetivo ……

3 Desenvolvimento ……..

4 Resultados ……...

5 Discussão ……

6 Conclusão ……

1 Introdução

A detecção de bordas é uma das etapas mais fundamentais do processamento de imagem, pois fornece informações estruturais sobre os objetos presentes em uma cena. As bordas indicam variações bruscas de intensidades de brilho, delimitando regiões e permitindo identificar formas, contornos e transições entre áreas distintas. Neste trabalho, implementamos o operador gradiente de forma manual, realizando uma comparação com o detector de bordas **Canny,** utilizando o índice SSIM (Structural Similarity Index) como métrica de similaridade

2 Objetivo

O objetivo deste trabalho é implementar e analisar o desempenho de um detector de bordas baseado no operador gradiente, utilizando os operadores Sobel e Prewitt, e comparar seus resultados com o detector Canny da biblioteca **skimage**. As principais metas são:

- Aplicar uma filtragem gaussiana 3x3 para reduzir ruídos na imagem;
- Calcular componentes horizontais e verticais do gradiente (Gx e Gy) por convolução manual;
- Determinar a magnitude e a direção do gradiente;
- Aplicar a supressão de não-máximos e a histerese para definir as bordas finais;
- Comparar o desempenho e a qualidade visual entre Sobel, Prewitt e Canny, analisando também o impacto dos limiares utilizados.

3 Desenvolvimento

O desenvolvimento do trabalho foi baseado em um pipeline completo de detecção de bordas, dividido em etapas bem definidas. Que são elas:

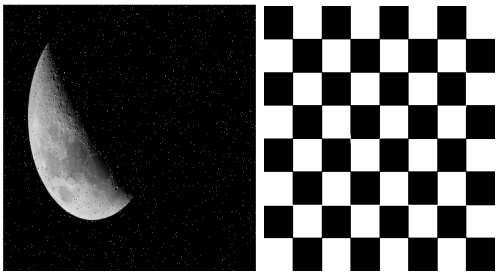
Entrada: A imagem de entrada foi carregada em escala de cinza utilizando a biblioteca OpenCV(cv2). Foram utilizados diferentes arquivos de teste, como a "*img02.jpg"*, "*lua1.gray.jpg", "chessboard_inv.png"* e a *"moedas.png"* (essas abaixo), de modo a avaliar o comportamento do algoritmo em contextos distintos.



img02.jpg



moedas.png



lua1.gray.jpg *chessboard_inv.png*

Filtragem gaussiana: Antes da aplicação dos operadores derivativos, a imagem foi suavizada com um filtro gaussiano 3x3, reduzindo o ruído de alta frequência que poderia causar falsas bordas. O kernel aplicado foi:

$$\frac{1}{16}\begin{bmatrix}1 & 2 & 1\\ 2 & 4 & 2\\ 1 & 2 & 1\end{bmatrix}$$

Essa etapa teve como objetivo eliminar pequenas flutuações de intensidade, tornando as bordas mais consistentes

Cálculo dos componentes Gx e Gy: Foram implementadas convoluções manuais para aplicar as máscaras dos operadores Sobel e Prewitt nas direções horizontal (x) e vertical (y).

Máscaras de Sobel:

$$G_x = \begin{bmatrix}-1 & 0 & 1\\ -2 & 0 & 2\\ -1 & 0 & 1\end{bmatrix}, \quad G_y = \begin{bmatrix}-1 & -2 & -1\\ 0 & 0 & 0\\ 1 & 2 & 1\end{bmatrix}$$

Máscaras de Prewitt:

$$G_x = \begin{bmatrix}-1 & 0 & 1\\ -1 & 0 & 1\\ -1 & 0 & 1\end{bmatrix}, \quad G_y = \begin{bmatrix}-1 & -1 & -1\\ 0 & 0 & 0\\ 1 & 1 & 1\end{bmatrix}$$

Essas máscaras permitem calcular as derivadas discretas da imagem, representando a taxa de variação de brilho nos dois eixos.

Magnitude e Direção do Gradiente: A magnitude do gradiente foi obtida pela fórmula:

$$M(i,j) = \sqrt{(G_y(i,j))^2 + (G_x(i,j))^2}$$

Já a direção foi calculada com:

$$D(i,j) = \arctan \frac{G_y(i,j)}{G_x(i,j) + \varepsilon}$$

O uso da função arctan garante resultados corretos em todos os quadrantes, evitando ambiguidades em ângulos negativos.

Supressão de Não-Máximos: Nesta etapa, o algoritmo percorre a matriz de magnitudes e mantém apenas os pixels que representam máximos locais na direção do gradiente, suprimindo os demais. Essa técnica reduz o espessamento das bordas e mantém apenas os contornos mais significativos.

Limiarização e Histerese: Para tornar o algoritmo adaptativo a diferentes condições, os limiares não foram escolhidos como valores fixos absolutos, mas sim baseados na estatística da imagem (mediana das magnitudes dos gradientes não nulos).

No experimento realizado, foram utilizados os seguintes valores multiplicantes para cada imagem, considerando a necessidade da mesma:

- *"img02.jpg"*
  - **T_H (Limiar Alto):** Mediana * 9.0
  - **T_L (Limiar Baixo):** Mediana * 5.0
  - **Justificativa:** A imagem apresenta baixo contraste geral, mas uma textura indesejada na casca do ovo. Por isso, optou-se por multiplicadores altos para filtrar essa textura (ruído) e preservar apenas as bordas estruturais do ovo e do prato.
- *"lua1.gray.jpg"*
  - **T_H (Limiar Alto):** Mediana * 3.0
  - **T_L (Limiar Baixo):** Mediana * 0.8
  - **Justificativa:** A imagem possui uma variedade muito grande de ruído (estrelas). Por conta disso, utilizou-se de um T_H moderado para ignorar as estrelas, e um T_L baixo para garantir que o contorno da lua fosse conectado.
- *"chessboard_inv.png"*
  - **T_H (Limiar Alto):** Mediana * 0.8
  - **T_L (Limiar Baixo):** Mediana * 0.4
  - **Justificativa:** Sendo uma imagem de alto contraste, a detecção é trivial e a mediana dos gradientes é alta. Limiares menores que 1.0 foram suficientes para capturar as bordas.

- *“moedas.png”*
    - **T_H (Limiar Alto):** Mediana * 1.0
    - **T_L (Limiar Baixo):** Mediana * 0.5
    - **Justificativa:** Tendo em vista a diversidade de texturas nessa imagem, foi necessário utilizar um limiar equilibrando, buscando capturar tanto o contorno externo da moeda quanto os detalhes do rosto e letras internas.

Os pixels com magnitude superior a T_H foram classificados como bordas fortes. Já os pixels entre T_L e T_H foram classificados como bordas fracas. Durante a etapa de histerese, as bordas fracas só foram preservadas caso estivessem conectadas fisicamente a uma borda forte.

Comparação com o Detector Canny (skimage): Para validar os resultados, aplicou-se o detector Canny da biblioteca skimage.filters. Em seguida, foi calculado o índice SSIM (Structural Similarity Index) para quantificar a similaridade entre a imagem obtida manualmente e o resultado do Canny. Os valores de SSIM ficaram entre 0.5792 e 0.9358, indicando alta similaridade.

- *“img02.jpg”*
    - SSIM = 0.5792
- *“lua1.gray.jpg”*
    - SSIM = 0.6934
- *“chessboard_inv.png”*
    - SSIM = 0.9358
- *“moedas.png”*
    - SSIM = 0.6237

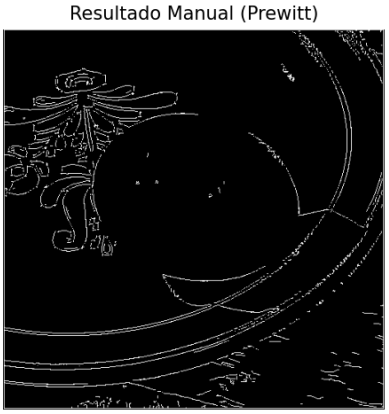
4 Resultados

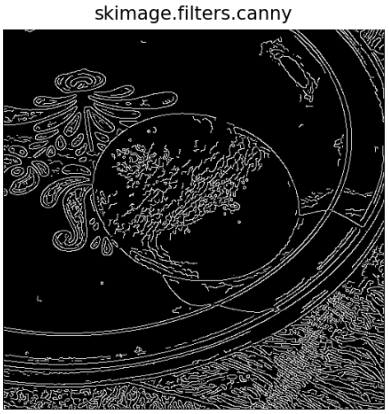
A seguir, apresentam-se as imagens obtidas e os seus operadores

- *“img02.jpg”*

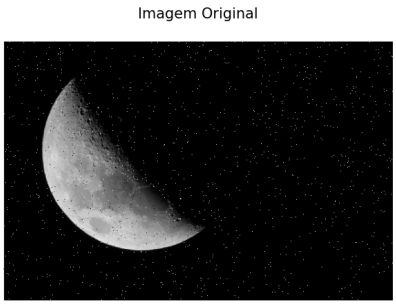


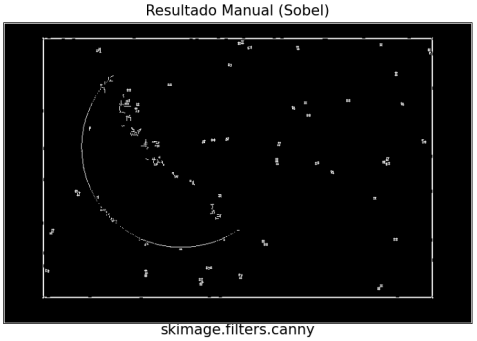


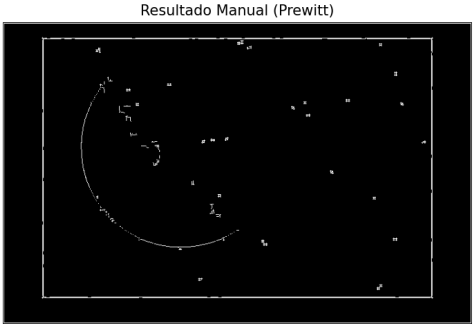


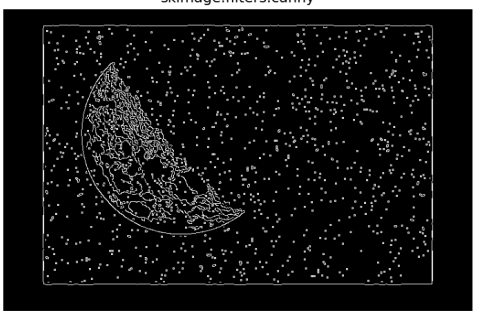


- *“lua1.gray.jpg”*

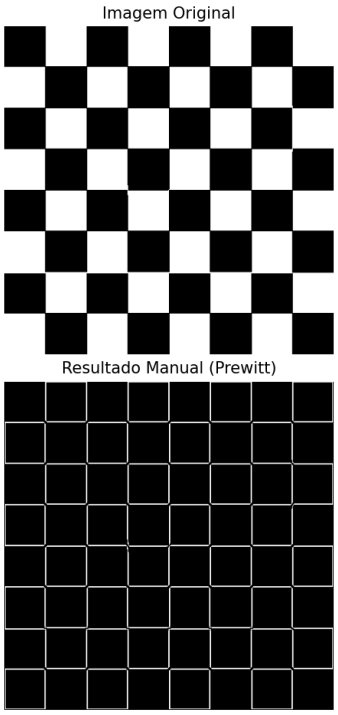


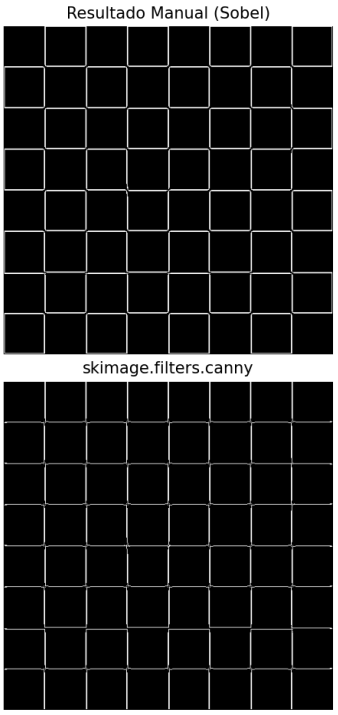






- *“chessboard_inv.png”*

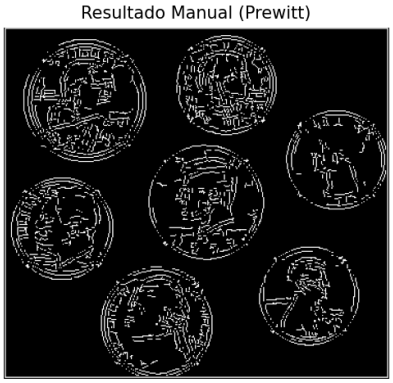


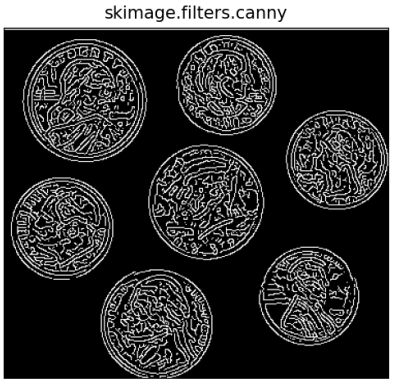


- *“moedas.png”*









Visualmente, observa-se que os operadores Sobel e Prewitt produzem resultados muito semelhantes, com bordas bem definidas nas regiões de transição. Teoricamente, o

método Sobel tende a apresentar maior suavidade devido à ponderação central em seu kernel, enquanto o Prewitt é ligeiramente mais sensível a ruídos, porém, na prática, essa diferença foi sutil. Já a comparação com o “skimage” revelou que o detector manual completo (incluindo supressão de não-máximos e histerese), quando devidamente parametrizado, é capaz de produzir bordas tão contínuas e limpas quanto a biblioteca de referência, chegando a superar o desempenho padrão na supressão de texturas indesejadas (como na imagem do ovo).

5 Discussão

Os resultados obtidos demonstram que o operador de gradiente, inserido em um pipeline completo, é uma abordagem eficaz para a detecção de bordas. A filtragem gaussiana inicial mostrou-se essencial para reduzir ruídos e evitar falsas detecções, enquanto a supressão de não-máximos foi determinante para afinar as arestas e preservar apenas os contornos relevantes. A comparação entre Sobel e Prewitt indica que ambos produzem mapas de gradiente coerentes.

A implementação manual da histerese foi o diferencial para entregar resultados refinados, conectando fragmentos de borda de forma inteligente. O índice SSIM confirmou a alta similaridade estrutural entre a abordagem manual e o detector de referência. Por fim, o impacto da escolha dos limiares T_L e T_H foi o fator mais significativo do experimento: a abordagem adaptativa, utilizando multiplicadores da mediana que variaram de 0.4 (para alto contraste) até 9.0 (para supressão de ruído), mostrou-se superior ao uso de limiares fixos. Isso permitiu um equilíbrio ideal entre sensibilidade e precisão para cada tipo de imagem.

6 Conclusão

O trabalho permitiu compreender profundamente as etapas que compõem o algoritmo de Canny, desde a filtragem inicial até a histerese final. A implementação manual reforçou a importância matemática de cada operação. A comparação final evidenciou que a eficiência da detecção de bordas depende menos da ferramenta (Manual vs. Biblioteca) e mais da correta parametrização dos limiares adaptativos, validando o pipeline proposto como robusto e funcional.